Optimización mediante Algoritmos Genéticos de la asignación y el balance de carga de alertas de seguridad en Centros de Operaciones de Seguridad (SOC)

Chacón, A.; Tabini, A.; Carloni, N.I.; Mierez, J.

Universidad Tecnológica Nacional, Facultad Regional Rosario

Abstract

El presente trabajo aborda el desafío del scheduling y asignación de alertas en un Centro de Operaciones de Seguridad (SOC) empleando un Algoritmo Genético Canónico. El volumen masivo de alertas de seguridad excede frecuentemente la capacidad humana, derivando en sobrecarga, fatiga de alertas y potenciales brechas en los Acuerdos de Nivel de Servicio (SLA) para incidentes críticos. Para resolver este problema de optimización combinatoria bajo restricciones, se desarrolló una estrategia evolutiva enfocada en minimizar simultáneamente el tiempo total de resolución, los tiempos de espera y el desbalance de carga entre un número finito de analistas. La metodología propuesta valida empíricamente el algoritmo utilizando una muestra de datos reales derivados del dataset público CICIDS2017 y compara sus resultados operativos con una asignación Round-Robin. La comparación considera espera crítica, backlog y desbalance de carga, métricas directamente relacionadas con la operación del SOC.

Palabras Clave

Algoritmos Genéticos, Centro de Operaciones de Seguridad (SOC), Scheduling, Asignación de Tareas, Balance de Carga, CICIDS2017.

Introducción

Los Centros de Operaciones de Seguridad (SOC) reciben un volumen de alertas que crece con mayor velocidad que la disponibilidad de analistas capacitados para atenderlas. La experiencia y la literatura especializada coinciden en que la sobrecarga (*alert overload*) es uno de los problemas estructurales más persistentes de la operación de un SOC, ya que obliga a decidir con información incompleta y bajo presión de tiempo qué atender primero.

Esa sobrecarga tiene un correlato humano bien documentado en la industria: la fatiga de alertas (*alert fatigue*). Un relevamiento sistemático reciente informa que la mayoría de las organizaciones recibe más de 10.000 alertas diarias y que más del 50 % son falsos positivos [3]. En este contexto, los analistas pueden llegar a ignorar alertas, desactivarlas o delegarlas a colegas, en lugar de investigarlas [3]. La fatiga degrada la calidad de las decisiones de triaje, incrementa el tiempo de respuesta y favorece la rotación del personal capacitado. El resultado es un ciclo que se retroalimenta: más alertas, analistas menos efectivos y tiempos de respuesta más largos, con el agravante de que la demora en atender una alerta de alta severidad incrementa el riesgo de que una intrusión progrese sin ser contenida.

A esta escasez estructural se suma un problema de coordinación: aun cuando el equipo de analistas es suficiente en promedio, la forma en que las alertas se reparten entre ellos rara vez es óptima. Las prácticas habituales de asignación —turnos fijos, reglas estáticas por tipo de alerta o asignación manual según disponibilidad aparente— no consideran de forma simultánea la prioridad de cada alerta, el plazo de resolución comprometido (SLA), el tiempo estimado que insumirá resolverla y la carga ya acumulada por cada analista. El resultado observado en la práctica es un desbalance de carga: algunos analistas acumulan *backlog* mientras otros permanecen subutilizados.

El problema fundamental es que la asignación manual no logra minimizar simultáneamente el tiempo total de resolución, los tiempos de espera de las alertas críticas y el desbalance de carga. Por ello, la presente investigación propone diseñar, implementar

y evaluar un modelo de Algoritmo Genético Canónico (AG) que distribuya las alertas —caracterizadas por su prioridad, severidad, tiempo estimado de resolución y SLA— entre un número limitado de analistas de forma óptima.

Este planteo se relaciona con la priorización de alertas estudiada por Jalalvand et al. [3], quienes organizan los criterios relevantes en dimensiones asociadas con la alerta, el analista, el activo, la organización y el entorno externo. En particular, su relevamiento destaca la necesidad de combinar criterios técnicos con restricciones de recursos humanos y de tiempo, en lugar de ordenar las alertas únicamente por severidad.

Elementos del Trabajo y metodología

La metodología propuesta se enmarca en la resolución de problemas de optimización combinatoria (específicamente *Job Shop Scheduling*) mediante el uso de Algoritmos Genéticos Canónicos.

La asignación de tareas con tiempos de procesamiento y recursos limitados puede formalizarse como una variante de *Job Shop Scheduling* (JSP), una clase de problemas NP-hard; cuando los tiempos efectivos presentan incertidumbre, el problema se aproxima al *Stochastic Job Shop Scheduling* (SJSP) [4]. En este trabajo se utiliza una instancia determinista con tiempos estimados, por lo que la referencia al SJSP fundamenta una posible extensión de robustez y no implica que la implementación actual modele fallas o distribuciones estocásticas.

Se diseñó una representación cromosómica específica donde cada individuo (cromosoma) codifica una asignación completa de alertas a analistas. Cada gen representa una alerta, y el alelo contenido indica el analista responsable de resolverla.

Esta codificación directa resulta adecuada para representar la decisión principal del problema —qué analista recibe cada alerta— y evita introducir una capa de codificación indirecta. Boukedroun et al. [4] reportan que las codificaciones directas pueden representar el cronograma en la estructura de datos y reducir la necesidad de mecanismos complejos de reparación, criterio que se adopta aquí mediante alelos acotados al conjunto de analistas disponibles.

La función de evaluación o *fitness* fue formulada para buscar el menor impacto temporal y el mayor equilibrio, combinando el tiempo total estimado de resolución con penalizaciones estrictas por:

- Tiempos de espera prolongados.
- Incumplimiento de SLA (especialmente en alertas críticas).
- Desbalance de carga entre los analistas operativos.

Formalmente, el algoritmo minimiza una penalización operativa P y transforma su resultado en una aptitud positiva a maximizar:

$$\begin{aligned} J &= 0.10\,\widehat{T} + 0.10\,\widehat{W} + 0.20\,\widehat{W}_c + 0.25\,\widehat{R}_c \\ &\quad + 0.10\,\widehat{B}_p + 0.05\,\widehat{B}_m + 0.15\,D + 0.05\,O, \\ f &= \frac{1}{1+J}. \end{aligned} \tag{1}$$

Aquí, las variables con sombrero representan magnitudes normalizadas: $\widehat{T}$ es el makespan relativo al horizonte, $\widehat{W}$ la espera promedio, $\widehat{W}_c$ la espera crítica, $\widehat{R}_c$ el retraso crítico respecto del SLA, $\widehat{B}_p$ el backlog ponderado por prioridad, $\widehat{B}_m$ los minutos de backlog, D el desbalance relativo de carga y O la sobrecarga relativa. La configuración oficial utiliza $w_T = 0.10$; la ablación comparativa fija $w_T = 0$.

El algoritmo evoluciona la población generación tras generación aplicando selección por ranking, cruzamiento para recombinar asignaciones exitosas, mutación por gen y elitismo. La población inicial incluye una solución Round-Robin como referencia y la política de atención dinámica prioriza las alertas disponibles según prioridad, severidad y urgencia del SLA. La selección por torneo y por ruleta se conservan como alternativas reproducibles. Estos operadores forman

parte del marco clásico de planes reproductivos y operadores genéticos desarrollado por Holland, que también analiza la robustez de los planes evolutivos y el papel de las codificaciones en sistemas adaptativos [2].

La configuración oficial utiliza una población de $N = 50$ individuos y evoluciona durante $G = 200$ generaciones, es decir, hasta 10.000 evaluaciones de individuos por corrida. La probabilidad de cruzamiento de un punto es $P_c = 0.75$ y la probabilidad de mutación por gen es $P_m = 0.05$. Se preservan los tres mejores individuos por generación y se utiliza selección por ranking. El escenario principal contiene 100 alertas, diez analistas, un horizonte de 480 minutos y criticidad de activos derivada de un catálogo CMDB simulado. Se agregan un escenario de estrés con 120 alertas y un escenario de saturación con 500 alertas. Cada escenario se evalúa sobre 20 semillas (42–61), comparando el AG y Round-Robin con las mismas alertas y los mismos escenarios de duración para cada semilla. El grid search de 18 combinaciones se utilizó únicamente como exploración de hiperparámetros, con 15 generaciones por combinación; su mejor configuración ($N = 20$, $P_m = 0.05$, $P_c = 0.60$) no reemplaza la configuración oficial $N = 50$, $G = 200$.

Para validar empíricamente el modelo, se utilizó una base de datos representativa derivada del dataset público **CICIDS2017** [1]. A partir de una muestra aleatoria de eventos, se inyectaron sintéticamente atributos operativos (prioridad, severidad, SLA y tiempo estimado de resolución). La criticidad del activo se generó mediante un catálogo CMDB simulado, con 60 % de activos comunes, 30 % importantes y 10 % críticos. Esta decisión permite estudiar el término de criticidad aunque el dataset original no contiene inventario de activos; por lo tanto, esos valores no deben interpretarse como observaciones reales de la infraestructura.

La selección de estos atributos está alineada con la taxonomía de criterios de priorización de Jalalvand et al. [3]: prioridad y severidad representan propiedades de la alerta; el tiempo de resolución aproxima el tiempo disponible y la carga del analista; y el SLA expresa la dimensión organizacional de cumplimiento y oportunidad (*timeliness*). Esta correspondencia ofrece una justificación metodológica para la función de aptitud, aunque los atributos hayan sido generados sintéticamente.

Cada escenario genera una tabla de alertas derivadas con el tamaño indicado (100, 120 o 500 registros). La distribución de prioridades, la severidad y el tiempo estimado se calculan nuevamente para cada muestra y semilla; estos valores describen las instancias experimentales y no deben interpretarse como propiedades originales del dataset CICIDS2017.

Como baselines operativos se utilizaron tres reglas deterministas. Round-Robin asigna las alertas secuencialmente entre los analistas, sin considerar carga ni prioridad. Menor carga asigna cada alerta al analista con menor carga acumulada. Urgencia balanceada ordena las alertas por prioridad, severidad y SLA, y asigna cada una al analista con menor carga; por lo tanto, incorpora urgencia sin realizar búsqueda evolutiva. Estas reglas se utilizan como referencias heurísticas y no forman parte del entrenamiento del AG.

Resultados

Las ejecuciones del algoritmo se evaluaron mediante métricas operativas y se compararon con una asignación Round-Robin. La comparación multi-semilla utiliza medias, desvíos estándar, intervalos de confianza bootstrap y porcentaje de semillas en las que el AG mejora. La validación fuera de muestra usa escenarios de duración nuevos y compartidos por ambas soluciones, de modo que la comparación no favorece al método que optimiza.

Las figuras ilustran una corrida puntual y no se utilizan como evidencia suficiente de superioridad. Las conclusiones cuantitativas se extraen de `outputs/experimento/experimento_resumen.csv`, que separa los escenarios principal, de estrés

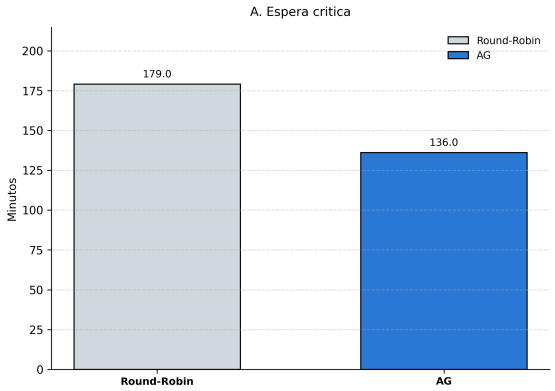


Figura 1: Espera crítica promedio para la corrida reproducida con la semilla 42.

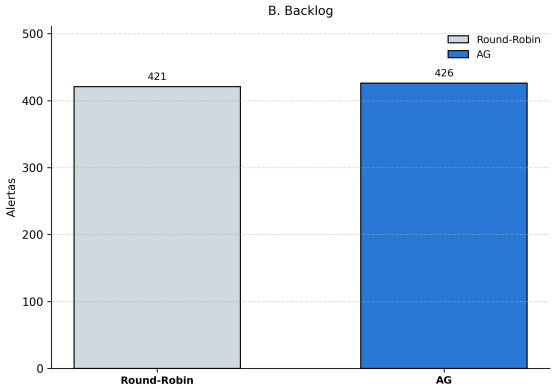


Figura 2: Backlog total para la corrida reproducida con la semilla 42.

y de saturación. En el escenario principal, el AG obtuvo un fitness medio de 0.8701 frente a 0.8602 de Round-Robin, redujo la espera crítica de 13.25 a 9.93 minutos y el desbalance de 0.1485 a 0.0952. Sin embargo, el cumplimiento global de SLA fue 88.99 % frente a 89.94 % y el backlog fue 16.67 frente a 15.36 alertas.

En el escenario de estrés, con 120 alertas, el AG mantuvo ventajas en fitness (0.8506 frente a 0.8418), espera crítica (16.14 frente a 19.82 minutos) y desbalance (0.0892 frente a 0.1260), pero presentó menor cumplimiento global de SLA (76.88 % frente a 79.34 %) y mayor backlog (32.31 frente a 29.54 alertas). El cumplimiento de SLA de alertas críticas fue superior para el AG en ambos escenarios no saturados: 85.45 % frente a 79.82 % en el escenario principal y

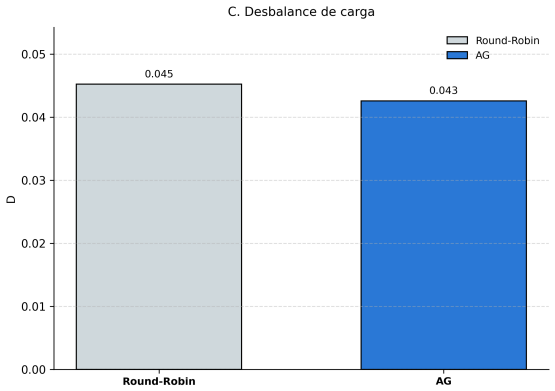


Figura 3: Desbalance relativo de carga para la corrida reproducida con la semilla 42.

74.59 % frente a 69.57 % en el de estrés.

El escenario de 500 alertas está deliberadamente sobredimensionado respecto del horizonte y se interpreta como saturación, no como escenario operativo principal. Allí el AG redujo la espera crítica de 182.96 a 150.68 minutos y el desbalance de 0.0552 a 0.0465, pero aumentó el backlog de 421.57 a 423.38 alertas y redujo el cumplimiento global de SLA de 9.04 % a 8.66 %. Por lo tanto, el escenario saturado confirma que el backlog total queda dominado por la insuficiencia estructural de capacidad.

A partir del análisis generacional se observaron además las siguientes medidas:

- **Fitness y estabilidad:** el AG superó a Round-Robin en fitness en las 20 semillas de los tres escenarios; las medias fueron 0.8701, 0.8506 y 0.4518 para 100, 120 y 500 alertas, respectivamente.

- **Cumplimiento de SLA:** el AG mejoró el cumplimiento de alertas críticas en los tres escenarios, pero redujo el cumplimiento global. En activos críticos no hubo diferencia clara en los escenarios de 100 y 120 alertas, mientras que el AG fue inferior en el escenario saturado.

- **Espera y balance:** el AG redujo la espera crítica y el desbalance en los tres

escenarios, aunque aumentó la espera promedio y no mostró una mejora concluyente en la espera de activos críticos.

- **Capacidad:** el backlog se analiza separando los escenarios no colapsados de la saturación de 500 alertas.

El archivo de distribución final muestra las cargas asignadas de la corrida oficial. En el grid search de 18 configuraciones, la mejor aptitud fue obtenida con población 20, mutación 0.05 y cruzamiento 0.60. Además, la comparación de baselines mostró que la regla de urgencia balanceada puede distribuir mejor la carga, mientras que el AG obtiene una espera crítica menor. Este resultado refuerza que no existe dominancia simultánea en todas las métricas.

Los pesos de la función objetivo se mantienen fijos antes de observar los resultados. No se modifican para forzar una ventaja del AG sobre Round-Robin; si existe un compromiso entre balance, espera crítica y SLA, se informa explícitamente.

Los intervalos bootstrap del resumen permiten distinguir efectos consistentes de resultados exploratorios. En los tres escenarios, las mejoras del AG en fitness, espera crítica y desbalance no incluyeron el cero en el intervalo de confianza. En cambio, el efecto sobre el cumplimiento global de SLA y el backlog fue desfavorable para el AG. La métrica de SLA sobre activos críticos no mostró una diferencia concluyente en los escenarios principal y de estrés.

Discusión

Los resultados obtenidos muestran que la función de aptitud multifactorial permite mejorar algunos objetivos operativos frente a Round-Robin, pero no todos simultáneamente. En particular, el AG mejora de forma consistente la espera de alertas críticas y el balance de carga, a costa de un mayor backlog y menor cumplimiento global de SLA.

A diferencia de los enfoques estáticos manuales, el Algoritmo Genético permite expresar en una única función objetivo el tiempo de resolución, la espera crítica, el backlog y el balance de carga. Sin embargo, la comparación de esta corrida no muestra una superioridad automática frente a Round-Robin en todas las métricas. Esto es consistente con la observación de Jalalvand et al. [3] de que los métodos de optimización permiten incorporar explícitamente restricciones como la disponibilidad de analistas y el tiempo de investigación, aunque permanecen menos explorados que los enfoques basados en aprendizaje automático. En consecuencia, el modelo propuesto se interpreta como una forma de Alert Prioritisation (AP) automatizada para el triaje y la asignación inicial, no como un reemplazo de la validación experta ante incidentes nuevos o ambiguos.

El backlog total no debe leerse de la misma manera en todos los escenarios. En la saturación de 500 alertas, la demanda supera ampliamente la capacidad del turno y el backlog queda dominado por ese límite estructural. En los escenarios de 100 y 120 alertas, en cambio, el aumento de backlog del AG sí representa un costo de la política de priorización y debe informarse junto con la mejora en alertas críticas.

El costo computacional se reporta junto con las métricas de calidad para determinar si la reoptimización por lote resulta operativamente viable. La evaluación fuera de muestra evita que la mejora observada sea atribuida únicamente a los escenarios usados durante la optimización. La literatura de scheduling vincula la reducción y estabilización del tiempo crítico de procesamiento con una mayor robustez frente a perturbaciones [4].

Conclusión

El presente trabajo demuestra empíricamente la viabilidad de utilizar Algoritmos Genéticos Canónicos para abordar el problema de asignación de alertas en un SOC. Se modeló una representación cromosómica y una función de evaluación que integran tiempo de resolución, espera crítica, backlog, balance de carga y criticidad de activos. La

evaluación sobre 20 semillas y tres niveles de demanda muestra que el AG mejora consistentemente el fitness, la espera de alertas críticas y el desbalance, pero no domina a Round-Robin en todas las métricas: aumenta el backlog y reduce el cumplimiento global de SLA. Por ello, la contribución debe interpretarse como una política de priorización y balance con un compromiso operativo explícito, no como una mejora universal.

Como líneas de trabajo futuro, se propone avanzar desde la automatización hacia una colaboración Humano–IA y hacia flujos continuos de alertas: los analistas podrían revisar las asignaciones y ajustar dinámicamente los pesos de las penalizaciones mediante retroalimentación activa. También se evaluará la robustez del cronograma frente a distribuciones de duración más diversas, cambios de disponibilidad y llegadas en tiempo real. La criticidad del activo ya se incorpora mediante un catálogo CMDB simulado; una extensión posterior deberá conectarla con un inventario real y con atributos de vulnerabilidad y dependencia. Estas líneas responden a las brechas identificadas por Jalalvand et al. [3] y a la perspectiva de robustez del SJSP estudiada por Boukedroun et al. [4].

Agradecimientos

A la cátedra de Algoritmos Genéticos por el marco metodológico, orientación técnica y soporte brindado para el desarrollo integral de la presente investigación.

Referencias

[1] Sharafaldin, I., Lashkari, A. H., y Ghorbani, A. A. (2018). *Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization*. CICIDS2017.

[2] Holland, J. H. (1992). *Adaptation in Natural and Artificial Systems*. MIT Press.

[3] Jalalvand, F., Chhetri, M. B., Nepal, S., y Paris, C. (2024). *Alert Prioritisation in Security Operations Centres: A Systematic Survey on Criteria and Methods*. ACM Computing Surveys, 57(2), 1–36. https://doi.org/10.1145/3695462

[4] Boukedroun, M., Duvivier, D., Ait-el-Cadi, A., Poirriez, V., y Abbas, M. (2023). *A hybrid genetic algorithm for stochastic job-shop scheduling problems*. RAIRO–Operations Research, 57(4), 1617–1645. https://doi.org/10.1051/ro/2023067

Datos de Contacto:
Chacón, A.; Tabini, A.; Carloni, N.I.; Mierez, J. Universidad Tecnológica Nacional, Facultad Regional Rosario. Zeballos 1341, Rosario, Santa Fe. E-mail: alumnos@utn.edu.ar.