Optimización mediante Algoritmos Genéticos de la asignación y el balance de carga de alertas de seguridad en Centros de Operaciones de Seguridad (SOC)

Abstract

El presente trabajo aborda el problema de asignación y scheduling de alertas en un Centro de Operaciones de Seguridad (SOC) mediante un Algoritmo Genético con selección por ranking, elitismo y operadores adaptados a la representación utilizada. El volumen de alertas puede exceder la capacidad humana, generando sobrecarga y riesgo de incumplimiento de los Acuerdos de Nivel de Servicio (SLA) para incidentes críticos. Se desarrolló una función objetivo ponderada que combina tiempo de resolución, espera, cumplimiento de SLA, backlog y balance de carga entre analistas. La evaluación utiliza alertas derivadas del dataset público CICIDS2017 y complementadas con atributos operativos sintéticos. El algoritmo se compara con Round-Robin, Menor carga, Urgencia balanceada y una búsqueda aleatoria con igual presupuesto. En 20 semillas, el AG supera a Round-Robin en fitness en los escenarios de 100 y 120 alertas y reduce en promedio la espera crítica y el desbalance en esos escenarios no saturados; en saturación, en cambio, aumenta la espera crítica. Además, obtiene mayor fitness medio que una búsqueda aleatoria con igual presupuesto. Sin embargo, Menor carga lo supera en fitness en los tres escenarios y Urgencia balanceada obtiene el mayor fitness en saturación; por lo tanto, no se observa una superioridad del AG frente a heurísticas deterministas simples.

Palabras Clave

Algoritmos Genéticos, Centro de Operaciones de Seguridad (SOC), Scheduling, Asignación de Tareas, Balance de Carga, CICIDS2017.

Introducción

Los Centros de Operaciones de Seguridad (SOC) reciben un volumen de alertas que crece con mayor velocidad que la disponibilidad de analistas capacitados para atenderlas. La experiencia y la literatura especializada coinciden en que la sobrecarga (*alert overload*) es uno de los problemas estructurales más persistentes de la operación de un SOC, ya que obliga a decidir con información incompleta y bajo presión de tiempo qué atender primero.

Esa sobrecarga tiene un correlato humano bien documentado en la industria: la fatiga de alertas (*alert fatigue*). Un relevamiento sistemático reciente informa que la mayoría de las organizaciones recibe más de 10.000 alertas diarias y que más del 50 % son falsos positivos [3]. En este contexto, los analistas pueden llegar a ignorar alertas, desactivarlas o delegarlas a colegas, en lugar de investigarlas [3]. La fatiga degrada la calidad de las decisiones de triaje, incrementa el tiempo de respuesta y favorece la rotación del personal capacitado. El resultado es un ciclo que se retroalimenta: más alertas, analistas menos efectivos y tiempos de respuesta más largos, con el agravante de que la demora en atender una alerta de alta severidad incrementa el riesgo de que una intrusión progrese sin ser contenida.

A esta escasez estructural se suma un problema de coordinación: aun cuando el equipo de analistas es suficiente en promedio, la forma en que las alertas se reparten entre ellos rara vez es óptima. Las prácticas habituales de asignación —turnos fijos, reglas estáticas por tipo de alerta o asignación manual según disponibilidad aparente— no consideran de forma simultánea la prioridad de cada alerta, el plazo de resolución comprometido (SLA), el tiempo estimado que insumirá resolverla y la carga ya acumulada por cada analista. El resultado observado en la práctica es un desbalance de carga: algunos analistas acumulan *backlog* mientras otros permanecen subutilizados.

El problema fundamental es que la asignación manual no logra equilibrar de forma consistente el tiempo total de resolución, los tiempos de espera de las alertas críticas y el desbalance de carga. Por ello, la presente investigación propone diseñar, imple-

mentar y evaluar un modelo de Algoritmo Genético (AG) que distribuya las alertas —caracterizadas por su prioridad, severidad, tiempo estimado de resolución y SLA— entre un número limitado de analistas mediante una función objetivo ponderada.

Este planteo se relaciona con la priorización de alertas estudiada por Jalalvand et al. [3], quienes organizan los criterios relevantes en dimensiones asociadas con la alerta, el analista, el activo, la organización y el entorno externo. En particular, su relevamiento destaca la necesidad de combinar criterios técnicos con restricciones de recursos humanos y de tiempo, en lugar de ordenar las alertas únicamente por severidad.

Elementos del Trabajo y metodología

La metodología propuesta se enmarca en la resolución de un problema de asignación y scheduling en máquinas paralelas mediante un Algoritmo Genético. Cada alerta se modela como una tarea asignada a un analista y no posee una ruta de múltiples operaciones.

La asignación de tareas con tiempos de procesamiento y recursos limitados se formula directamente como *parallel machine scheduling* con tiempos estocásticos. Cada alerta es una tarea de una sola operación y los analistas actúan como máquinas paralelas. Los tiempos nominales se complementan con duraciones lognormales de media igual al tiempo estimado y coeficiente de variación configurable. El AG optimiza el valor esperado sobre escenarios comunes y la solución se valida con escenarios nuevos fuera de muestra.

Se diseñó una representación cromosómica específica con tres bloques: asignación de alertas a analistas, ajuste de prioridad de despacho y una política global de criticidad. El primer bloque contiene un gen por alerta y su alelo indica el analista responsable; el segundo bloque contiene un ajuste acotado d_i para la alerta i, que modifica el orden base; el tercero contiene dos genes globales (w_2, w_3), acotados, que determinan cuánto utiliza la política evolucionada la criticidad de activos importantes y críticos. Las variantes reducidas desactivan el bloque de ajuste o el de criticidad, respectivamente.

Esta codificación directa resulta adecuada para representar la decisión principal del problema —qué analista recibe cada alerta— y evita introducir una capa de codificación indirecta. El segundo bloque permite evolucionar una política de despacho específica por alerta y los dos genes globales permiten interpretar directamente la sensibilidad aprendida para cada nivel de criticidad, sin duplicar genes por alerta ni alterar los datos observados de la instancia. Boukedroun et al. [4] reportan que las codificaciones directas pueden representar el cronograma en la estructura de datos y reducir la necesidad de mecanismos complejos de reparación, criterio que se adopta aquí mediante alelos acotados al conjunto de analistas disponibles y ajustes limitados.

La función de evaluación o *fitness* fue formulada para buscar el menor impacto temporal y el mayor equilibrio, combinando el tiempo total estimado de resolución con penalizaciones estrictas por:

- Tiempos de espera prolongados.
- Incumplimiento de SLA (especialmente en alertas críticas).
- Desbalance de carga entre los analistas operativos.

Formalmente, el algoritmo minimiza una única función objetivo escalarizada J, que pondera varios criterios operativos, y transforma su resultado en una aptitud positiva a maximizar:

$$\begin{aligned} J &= 0.10\,\widehat{T} + 0.10\,\widehat{W} + 0.20\,\widehat{W}_c + 0.25\,\widehat{R}_c \\ &\quad + 0.10\,\widehat{B}_p + 0.05\,\widehat{B}_m + 0.15\,D + 0.05\,O \\ &\quad + 0.25\,\widehat{S}_a, \\ f &= \frac{1}{1+J}. \end{aligned} \tag{1}$$

Aquí, las variables con sombrero representan magnitudes normalizadas: $\widehat{T}$ es el makespan relativo al horizonte, $\widehat{W}$ la espera promedio,

$\widehat{W}_c$ la espera crítica, $\widehat{R}_c$ el retraso crítico respecto del SLA efectivo, $\widehat{B}_p$ el backlog ponderado por prioridad, $\widehat{B}_m$ los minutos de backlog, D el desbalance relativo de carga, O la sobrecarga relativa y $\widehat{S}_a$ la violación de SLA ponderada por prioridad y criticidad del activo. Los coeficientes suman 1.25 deliberadamente: el modelo prioriza el cumplimiento de SLA y la espera crítica por encima de makespan y balance, sin interpretar los coeficientes como probabilidades. La configuración oficial utiliza $w_T = 0.10$ y el término de activo tiene peso 0.25.

El algoritmo evoluciona la población generación tras generación aplicando selección por ranking, cruzamiento y mutación por bloques para recombinar asignaciones y ajustes de prioridad, además de elitismo. La población inicial incluye una solución Round-Robin con ajuste nulo como referencia y la política de atención dinámica prioriza las alertas disponibles según prioridad, severidad, ajuste evolucionado y política global de criticidad. La selección por torneo y por ruleta se conservan como alternativas reproducibles. Estos operadores forman parte del marco clásico de planes reproductivos y operadores genéticos desarrollado por Holland, que también analiza la robustez de los planes evolutivos y el papel de las codificaciones en sistemas adaptativos [2].

La configuración oficial utiliza una población de $N = 50$ individuos y evoluciona durante $G = 200$ generaciones, es decir, hasta 10.000 evaluaciones de individuos por corrida. La probabilidad de cruzamiento de un punto es $P_c = 0.75$ y la probabilidad de mutación por gen es $P_m = 0.05$. Se preservan los tres mejores individuos por generación y se utiliza selección por ranking. El escenario principal contiene 100 alertas, diez analistas, un horizonte de 480 minutos y criticidad de activos derivada de un catálogo CMDB simulado. Se agregan un escenario de estrés con 120 alertas y un escenario de saturación con 500 alertas. Cada escenario se evalúa sobre 20 semillas (42–61), comparando el AG y los baselines con las mismas alertas y los mismos escenarios de duración para cada semilla. La configuración reportada como "AG" en las tablas principales es la variante D, que contiene los tres bloques. La ablación separa cuatro variantes: A (solo asignación), B (asignación y d_i), C (asignación y (w_2, w_3)) y D (todos los bloques). El grid search de 18 combinaciones se utilizó únicamente como exploración preliminar de hiperparámetros, con 15 generaciones por combinación; la configuración oficial ($N = 50$, $G = 200$) se conserva porque permite evaluar el efecto de los operadores y la representación extendida con un presupuesto diez veces mayor de evaluaciones y coincide con la configuración usada en la campaña multi-semilla. La configuración de exploración ($N = 20$, $P_m = 0.05$, $P_c = 0.60$) no se presenta como resultado final porque no fue validada con la campaña completa.

Para validar empíricamente el modelo, se utilizó una base de eventos de red derivada del dataset público **CICIDS2017** [1]. El dataset aporta tráfico y etiquetas de actividad, que sirven como fuente reproducible de eventos y permiten variar la demanda entre escenarios; no aporta, sin embargo, inventario SOC ni tiempos de atención. Por eso se generaron sintéticamente prioridad, severidad, SLA y tiempo estimado de resolución, y la criticidad del activo mediante un catálogo CMDB simulado, con 60 % de activos comunes, 30 % importantes y 10 % críticos. Esta separación permite estudiar la política de asignación sin presentar los atributos operativos como observaciones reales de la infraestructura.

La selección de estos atributos está alineada con la taxonomía de criterios de priorización de Jalalvand et al. [3]: prioridad y severidad representan propiedades de la alerta; el tiempo de resolución aproxima el tiempo disponible y la carga del analista; y el SLA expresa la dimensión organizacional de cumplimiento y oportunidad (*timeliness*). En lo que sigue, "alerta crítica" refiere a una alerta marcada por su prioridad o severidad, mientras que "activo crítico" refiere exclusi-

vamente a la categoría de criticidad obtenida de la CMDB simulada. La criticidad observada del activo se integra en el cromosoma mediante el tercer bloque global (w_2, w_3): no se modifica artificialmente la criticidad de la instancia, sino que se aprende cuánto debe influir cada nivel en el orden de despacho. El orden efectivo resta $n \cdot 0.5 \cdot w_2$ a los activos importantes y $n \cdot 0.5 \cdot w_3$ a los críticos, donde n es el número de analistas. Además, la criticidad interviene en la función de penalización mediante el SLA efectivo y el peso de la violación. Esta correspondencia ofrece una justificación metodológica para la función de aptitud, aunque los atributos hayan sido generados sintéticamente.

Cada escenario genera una tabla de alertas derivadas con el tamaño indicado (100, 120 o 500 registros). La distribución de prioridades, la severidad y el tiempo estimado se calculan nuevamente para cada muestra y semilla; estos valores describen las instancias experimentales y no deben interpretarse como propiedades originales del dataset CICIDS2017.

Como baselines operativos se utilizaron tres reglas deterministas. Round-Robin asigna las alertas secuencialmente entre los analistas, sin considerar carga ni prioridad. Menor carga asigna cada alerta al analista con menor carga acumulada. Urgencia balanceada ordena las alertas por prioridad, severidad y SLA, y asigna cada una al analista con menor carga; por lo tanto, utiliza la misma información operativa que el AG sin realizar búsqueda evolutiva. Estas reglas no forman parte del entrenamiento del AG.

Además del esquema por lote, el prototipo implementa un flujo continuo mediante un horizonte rodante. En cada intervalo de replanificación se reoptimiza únicamente el conjunto de alertas ya llegadas y aún no iniciadas; las tareas que comienzan dentro del intervalo quedan comprometidas y se ejecutan con duraciones reales desconocidas por el planificador. Esta modalidad puede compararse con el AG por lote y los baselines bajo la misma realización de duraciones. La ejecución continua se utiliza como evaluación operativa complementaria y no reemplaza la comparación multi-semilla del escenario por lote.

Resultados

Las ejecuciones del algoritmo se evaluaron mediante métricas operativas y se compararon con los tres baselines deterministas. La comparación multi-semilla utiliza medias, desvíos estándar, intervalos de confianza bootstrap y porcentaje de semillas en las que el AG mejora. La validación fuera de muestra usa escenarios de duración nuevos y compartidos por todas las soluciones, de modo que la comparación no favorece al método que optimiza.

Las conclusiones cuantitativas se extraen de los registros experimentales multi-semilla, que separan los escenarios principal, de estrés y de saturación. Las Tablas 1–3 resumen seis métricas sobre 20 semillas y evitan basar la interpretación en una sola corrida.

Cuadro 1: Resultados medios sobre 20 semillas: escenario principal. AG = D. Fitness: mayor es mejor; el resto: menor es mejor.

Método	Fitness	Espera cr.	Backlog	Desbalance	SLA (%)	SLA cr. (%)
Round-Robin	0.8599	13.25	15.36	0.1485	89.94	79.82
Menor carga	0.8788	9.24	12.87	0.0820	94.94	87.70
Urgencia balanceada	0.8505	19.80	22.19	0.0798	75.53	68.86
AG (D)	0.8702	10.37	15.90	0.0948	89.78	84.47
A	0.8701	9.87	16.42	0.0953	89.19	85.75
B	0.8703	9.91	16.73	0.0945	89.20	85.49
C	0.8693	11.11	16.18	0.0946	89.23	83.64
D	0.8702	10.37	15.90	0.0948	89.78	84.47

Cuadro 2: Resultados medios sobre 20 semillas: escenario de estrés. AG = D. Fitness: mayor es mejor; el resto: menor es mejor.

Método	Fitness	Espera cr.	Backlog	Desbalance	SLA (%)	SLA cr. (%)
Round-Robin	0.8414	19.82	29.54	0.1260	79.34	69.57
Menor carga	0.8586	17.06	28.92	0.0751	83.38	73.74
Urgencia balanceada	0.8340	23.67	38.36	0.0735	65.68	62.93
AG (D)	0.8504	17.02	30.54	0.0884	78.07	74.43
A	0.8512	16.08	31.93	0.0879	76.81	74.48
B	0.8503	16.53	32.17	0.0883	76.73	73.96
C	0.8503	17.44	30.44	0.0887	78.57	72.90
D	0.8504	17.02	30.54	0.0884	78.07	74.43

Cuadro 3: Resultados medios sobre 20 semillas: escenario de saturación. AG = D. Fitness: mayor es mejor; el resto: menor es mejor.

Método	Fitness	Espera cr.	Backlog	Desbalance	SLA (%)	SLA cr. (%)
Round-Robin	0.4442	182.96	421.57	0.0552	9.04	19.17
Menor carga	0.4506	167.44	422.83	0.0363	8.70	19.50
Urgencia balanceada	0.4511	157.65	423.78	0.0361	8.55	18.96
AG (D)	0.4333	269.82	416.81	0.0521	9.72	17.38
A	0.4517	150.46	423.48	0.0462	8.59	20.52
B	0.4484	165.99	422.54	0.0460	8.91	20.64
C	0.4280	312.67	416.35	0.0480	9.49	17.04
D	0.4333	269.82	416.81	0.0521	9.72	17.38

Las filas A–D provienen de la ablación y se muestran como indicio de sensibilidad a la representación; no se interpretan como una repetición de los baselines, porque sus corridas no son la misma campaña que la comparación principal. En particular, A obtiene en saturación un fitness medio de 0.4517, superior al de D (0.4333), pero esta diferencia solo debe leerse dentro de la ablación.

En el escenario principal, el AG obtuvo un fitness medio de 0.8702 frente a 0.8599 de Round-Robin, pero Menor carga alcanzó 0.8788 y menor espera crítica (9.24 frente a 10.37 minutos). El backlog del AG fue 15.90 frente a 15.36 de Round-Robin, 12.87 de Menor carga y 22.19 de Urgencia balanceada, que presentó el peor backlog.

En el escenario de estrés, con 120 alertas, el AG mejoró frente a Round-Robin en fitness (0.8504 frente a 0.8414), espera crítica (17.02 frente a 19.82 minutos) y desbalance (0.0884 frente a 0.1260), pero presentó menor cumplimiento global de SLA (78.07 % frente a 79.34 %) y mayor backlog (30.54 frente a 29.54 alertas). Menor carga superó al AG en fitness (0.8586), backlog (28.92) y desbalance (0.0751). El cumplimiento de SLA de alertas críticas fue superior para el AG frente a Round-Robin en ambos escenarios no saturados: 84.47 % frente a 79.82 % en el escenario principal y 74.43 % frente a 69.57 % en el de estrés.

El escenario de 500 alertas está deliberadamente sobredimensionado respecto del horizonte y se interpreta como saturación. Allí Urgencia balanceada obtuvo el mayor fitness (0.4511) y la menor espera crítica (157.65), seguida por Menor carga (0.4506 y 167.44), Round-Robin (0.4442 y 182.96) y el AG (0.4333 y 269.82). El AG quedó último entre los cuatro métodos, aunque redujo el backlog (416.81 frente a 421.57 de Round-Robin). Este resultado no puede explicarse solo por la insuficiencia de capacidad: sugiere que la representación extendida y la búsqueda con 10.000 evaluaciones no encontraron una política robusta fuera de muestra. El sobreajuste a los escenarios de entrenamiento es una hipótesis pendiente de verificar con un diagnóstico explícito de fitness dentro de muestra.

Menor carga fue mejor que el AG en espera crítica en el escenario principal (9.24 frente a 10.37 minutos), aunque la diferencia no fue concluyente tras Holm ($p_{\text{Holm}} = 0.172$); en estrés los valores fueron prácticamente iguales y la diferencia no fue concluyente (17.06 frente a 17.02; $p_{\text{Holm}} = 1.000$). En saturación, Menor carga redujo la espera crítica de forma concluyente (167.44 frente a 269.82; $p_{\text{Holm}} < 0.001$) y Urgencia balanceada obtuvo un valor todavía menor (157.65). Los intervalos bootstrap y las pruebas de Wilcoxon con Holm se calcularon sobre las comparaciones pareadas de las 20 semillas.

A partir del análisis generacional se observaron además las siguientes medidas:

- **Fitness y estabilidad:** el AG superó a Round-Robin en fitness en las 20 semillas de los escenarios principal y de estrés, con diferencias pareadas concluyentes tras Holm ($p_{\text{Holm}} = 0.00012$ en ambos escenarios); en saturación fue inferior ($p_{\text{Holm}} = 0.00012$). Las medias fueron 0.8702, 0.8504 y 0.4333 para 100, 120 y 500 alertas, respectivamente. Menor carga superó al AG en fitness en los tres escenarios ($p_{\text{Holm}} = 0.00012$), mientras que Urgencia balanceada también lo superó en saturación ($p_{\text{Holm}} = 0.00012$).

- **Cumplimiento de SLA:** el AG mejoró el cumplimiento de alertas críticas en los escenarios principal y de estrés, pero

no en saturación; el cumplimiento global fue menor en los dos primeros y mayor en saturación. En activos críticos no hubo diferencia clara en los escenarios no saturados, mientras que el AG fue superior en saturación.

- **Espera y balance:** el AG redujo en promedio la espera crítica y el desbalance frente a Round-Robin en los escenarios principal y de estrés, pero la diferencia de Menor carga frente al AG fue no concluyente en espera crítica. En saturación el AG aumentó la espera crítica y quedó último entre los cuatro métodos; la diferencia de desbalance frente a Round-Robin no fue concluyente.

- **Capacidad:** el backlog se analiza separando los escenarios no colapsados de la saturación de 500 alertas, sin atribuir automáticamente a la capacidad toda diferencia de espera entre métodos.

El archivo de distribución final muestra las cargas asignadas de la corrida oficial. En el grid search de 18 configuraciones, la mejor aptitud fue obtenida con población 20, mutación 0.05 y cruzamiento 0.60. La configuración oficial utiliza una población mayor y más generaciones para realizar una búsqueda más estable y profunda que la exploración preliminar.

Como control adicional se ejecutó una búsqueda aleatoria con el mismo presupuesto computacional del AG: 10.000 evaluaciones por combinación de escenario y semilla. En cada caso se utilizaron la misma instancia, los mismos escenarios de duración y la misma validación fuera de muestra. El fitness medio del AG fue 0.8702, 0.8504 y 0.4333 en los escenarios principal, de estrés y de saturación, frente a 0.8478, 0.8265 y 0.4105 de la búsqueda aleatoria, respectivamente. La espera crítica media también fue menor para el AG en los escenarios principal y de estrés: 10.37 frente a 18.68 minutos y 17.02 frente a 27.59 minutos; en saturación también fue menor para el AG (269.82 frente a 364.70 minutos). Este control aporta indicios de que el AG encuentra mejores soluciones según su función objetivo que una búsqueda aleatoria con igual presupuesto, aunque no demuestra superioridad en todas las métricas ni frente a toda heurística alternativa.

Los pesos de la función objetivo se mantienen fijos antes de observar los resultados. No se modifican para forzar una ventaja del AG sobre Round-Robin; si existe un compromiso entre balance, espera crítica y SLA, se informa explícitamente.

La comparación de ablación se realizó de forma pareada por escenario y semilla, con intervalos bootstrap, prueba de Wilcoxon y corrección de Holm. En el escenario principal no se detectaron diferencias estadísticamente concluyentes entre las variantes en las métricas principales. En el escenario de estrés, C y D aumentaron el backlog frente a A en aproximadamente 1.49 y 1.39 alertas, respectivamente ($p_{\text{Holm}} = 0.040$ y 0.035), sin una mejora concluyente de fitness, espera crítica o desbalance. Bajo saturación, B, C y D redujeron la espera crítica frente a A en aproximadamente 15.5, 162.2 y 119.4 minutos, respectivamente (en todos los casos, $p_{\text{Holm}} < 0.001$), pero redujeron el fitness en 0.0032, 0.0237 y 0.0184 y aumentaron el backlog en 0.94, 7.13 y 6.68 alertas, respectivamente. D además redujo el desbalance frente a A en aproximadamente 0.006 ($p_{\text{Holm}} = 0.010$). Estos resultados muestran un compromiso: la política de criticidad puede reducir esperas críticas bajo sobrecarga, pero no mejora globalmente la función objetivo.

Los pesos globales (w_2, w_3) son más fáciles de interpretar en saturación, donde las variantes que incorporan criticidad reducen la espera de las alertas críticas frente a la variante A. Ese beneficio tiene un costo: esas variantes reducen el fitness global y aumentan el backlog frente a A, y no implica que el AG completo supere a los baselines. Como A es un subespacio de D, el peor resultado de D también es compatible con una búsque-

da perjudicada por el espacio extendido y el presupuesto de 10.000 evaluaciones. En los escenarios principal y de estrés varios pesos llegaron cerca del techo de 0.98, sin producir un efecto estadísticamente detectable. Por eso, la criticidad dentro del cromosoma debe interpretarse como una política de compromiso, no como una mejora general.

Los intervalos bootstrap del resumen permiten distinguir efectos consistentes de resultados exploratorios. Aunque el AG supera a Round-Robin en varias medias de fitness, espera crítica y desbalance, esas diferencias no deben interpretarse automáticamente como concluyentes. El efecto sobre el cumplimiento global de SLA y el backlog debe informarse junto con cualquier mejora en la espera crítica.

Este análisis tiene varias limitaciones estadísticas. La ablación comprende 105 comparaciones (35 por escenario) y la comparación multi-semilla de baselines agrega 63 comparaciones (21 por escenario); en la comparación de baselines, la corrección de Holm se aplicó sobre las 63 comparaciones en conjunto, por lo que el valor mínimo ajustado $p_{\text{Holm}} = 0.00012$ corresponde al mínimo exacto de Wilcoxon repetido en una familia de ese tamaño. La búsqueda aleatoria se reporta de forma descriptiva, sin una prueba pareada adicional ni intervalos propios en el CSV resumido, por lo que no se presenta como evidencia inferencial. Además, 20 semillas ofrecen poca potencia para detectar efectos pequeños, por lo que una diferencia no significativa no demuestra que los métodos sean exactamente iguales.

Discusión

Los resultados obtenidos muestran que la función de aptitud multifactorial permite mejorar algunos objetivos operativos frente a los baselines, pero no todos simultáneamente. En los escenarios principal y de estrés, el AG mejora frente a Round-Robin en espera crítica y desbalance, aunque Menor carga obtiene mayor fitness y menor espera crítica en el escenario principal, si bien la diferencia no fue concluyente tras Holm; en estrés, la espera fue similar (17.02 frente a 17.06 minutos). En saturación, el AG presenta el menor fitness y la mayor espera crítica de los cuatro métodos, aunque reduce el backlog frente a Round-Robin.

A diferencia de los enfoques estáticos manuales, el Algoritmo Genético permite expresar en una única función objetivo el tiempo de resolución, la espera crítica, el backlog y el balance de carga. Sin embargo, la comparación multi-semilla no muestra una superioridad automática frente a los baselines: Menor carga supera al AG en fitness en los tres escenarios, mientras que Urgencia balanceada también lo supera en saturación y ambos baselines obtienen menor espera crítica allí. Esto es consistente con la observación de Jalalvand et al. [3] de que los métodos de optimización permiten incorporar explícitamente restricciones como la disponibilidad de analistas y el tiempo de investigación, aunque permanecen menos explorados que los enfoques basados en aprendizaje automático. En consecuencia, el modelo propuesto se interpreta como una forma de Alert Prioritisation (AP) automatizada para el triaje y la asignación inicial, no como un reemplazo de la validación experta ante incidentes nuevos o ambiguos.

El backlog total no debe leerse de la misma manera en todos los escenarios. La saturación de 500 alertas supera ampliamente la capacidad del turno y limita el backlog alcanzable, pero la comparación con los baselines muestra que la política de despacho todavía modifica sustancialmente la espera crítica. Por eso, la peor espera del AG no se atribuye únicamente a la capacidad: también puede reflejar sobreajuste a los escenarios de duración usados durante la optimización o una exploración insuficiente del cromosoma extendido. En los escenarios de 100 y 120 alertas, el aumento de backlog del AG representa además un costo de la política de priorización y debe informarse junto con cualquier mejora en alertas críticas.

La evaluación fuera de muestra evita que

la mejora observada sea atribuida únicamente a los escenarios usados durante la optimización. La búsqueda aleatoria con igual presupuesto obtuvo menor fitness medio que el AG en los tres escenarios, lo que aporta un contraste descriptivo frente a la posibilidad de que la diferencia se explique solamente por el número de evaluaciones. La replanificación continua está implementada como extensión del prototipo, pero no se presenta aquí como evidencia cuantitativa principal. La literatura de scheduling vincula la reducción y estabilización del tiempo crítico de procesamiento con una mayor robustez frente a perturbaciones [4].

Conclusión

El presente trabajo proporciona evidencia experimental inicial sobre el uso de un Algoritmo Genético para abordar, bajo escenarios simulados con atributos operativos sintéticos, un problema de asignación de alertas en un SOC. Se modeló una representación cromosómica y una función de evaluación que integran tiempo de resolución, espera crítica, backlog, balance de carga y criticidad de activos. Sobre 20 semillas, el AG supera a Round-Robin en fitness en los escenarios de 100 y 120 alertas, con diferencias pareadas concluyentes tras Holm, y reduce en promedio la espera crítica y el desbalance, a costa de un backlog levemente mayor y un menor cumplimiento global de SLA. En el escenario de saturación ocurre lo contrario: el AG queda por debajo de Round-Robin en fitness y en espera crítica, aunque reduce el backlog y mejora el cumplimiento global de SLA. Frente a la búsqueda aleatoria con igual presupuesto obtiene mayor fitness medio en los tres escenarios, aunque esa comparación es descriptiva. Sin embargo, Menor carga obtiene mayor fitness que el AG en los tres escenarios, con diferencias concluyentes tras Holm, y Urgencia balanceada obtiene el mayor fitness en saturación. Por ello, la contribución debe interpretarse como una política experimental de priorización y balance con compromisos operativos explícitos, no como una mejora frente a heurísticas deterministas simples.

El modelo no mide directamente la fatiga de alertas: no representa habilidades diferenciadas, turnos, pausas ni una degradación del rendimiento por carga sostenida. En consecuencia, la fatiga se utiliza como motivación del problema y se aproxima mediante espera, backlog y cumplimiento de SLA, pero no se presenta como una variable validada experimentalmente.

Como líneas de trabajo futuro, quedan pendientes: (i) un diagnóstico de fitness dentro de muestra frente a fuera de muestra para confirmar o descartar sobreajuste en saturación; (ii) sembrar la población inicial con Menor carga y Urgencia balanceada; (iii) incorporar baselines con holgura de SLA, como EDF, y una cota por programación entera en una instancia pequeña. Cada corrida completa demanda aproximadamente una hora, por lo que estas extensiones se difieren a una segunda etapa. También se evaluará ampliar el rango superior de los pesos de criticidad, actualmente cercanos al techo de 0.98, para determinar si ese límite condiciona la búsqueda. Se avanzará desde la automatización hacia una colaboración Humano–IA, se evaluará la robustez frente a distribuciones de duración más diversas, cambios de disponibilidad y llegadas de mayor frecuencia, y se conectará la criticidad con un inventario real. Estas líneas responden a las brechas identificadas por Jalalvand et al. [3] y a la perspectiva de robustez del SJSP estudiada por Boukedroun et al. [4].

Agradecimientos

A la cátedra de Algoritmos Genéticos por el marco metodológico, orientación técnica y soporte brindado para el desarrollo integral de la presente investigación.

Referencias

[1] Sharafaldin, I., Lashkari, A. H., y Ghorbani, A. A. (2018). *Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization*. CICIDS2017.

[2] Holland, J. H. (1992). *Adaptation in Natural and Artificial Systems*. MIT Press.

[3] Jalalvand, F., Chhetri, M. B., Nepal, S., y Paris, C. (2024). *Alert Prioritisation in Security Operations Centres: A Systematic Survey on Criteria and Methods*. ACM Computing Surveys, 57(2), 1–36. https://doi.org/10.1145/3695462
[4] Boukedroun, M., Duvivier, D., Ait-el-Cadi, A., Poirriez, V., y Abbas, M. (2023). *A hybrid genetic algorithm for stochastic job-shop scheduling problems*. RAIRO–Operations Research, 57(4), 1617–1645. https://doi.org/10.1051/ro/2023067